

Design and Implementation of a Yemen Cars Pipeline, API and Deployment

Date

No.

فكرة المشروع :-

هو عبارة عن نظام يقوم بتجميع بيانات السيارات المعروضة للبيع أو الشراء في اليمن من موقع «السوق اليمني المفتوح» ثم تخزينها كبيانات خام، وبعد ذلك تنظفها وتوحيدها، وأخيراً تقديمها عبر API يمكن الوصول إليها كخدمة تعمل على Ubuntu.

المشكلة :-

بيانات السيارات المعروضة للبيع أو الشراء في موقع السوق اليمني المفتوح تكون مشوهة وتغير نظيفة حيث أنها تحتوي على نصوص طويلة أو حقول ناقصة مما يصعب استخدامها مباشرة للتحليل أو اتخاذ القرار، مما قد يؤدي إلى عدم فهم طبيعة السوق بشكل كامل.

أهداف المشروع :

الهدف العام : بناء نظام لجلب بيانات السيارات في اليمن من الويب وتنظيفها، تخزينها ثم تقديمها كخدمة قابلة للتشغيل.

الأهداف التفصيلية :

- 1- جمع بيانات السيارات في اليمن عن طريق Web Scraping
- 2- تخزين البيانات الخام أولاً، بحيث تكون في مرحلة Staging
- 3- تنظيف البيانات ونقلها إلى قاعدة بيانات أخرى CleanDB
- 4- توفير API باستخدام FastAPI للوصول إلى البيانات
- 5- تشغيل النظام كخدمة تعمل في الخلفية باستخدام systemd
- 6- فتح منفذ للوصول إلى المشروع عبر Firewall
- 7- تجهيز المشروع ليكون قابلاً للنشر كحزمة deb

Date

No.


Data Flow:

The System follows ETL Pipeline.

1. Scraper.py : Extracts Car data from OpenSooq.com and stores it as a raw CSV.
2. Processing.py : Cleans and Standardizes the data, saving the processed data into data/processed.
3. Loading.py : Loads and inserts the cleaned data into PostgreSQL database which simulates data warehouse job.
4. App/main.py : Serves the data through API endpoints using FastAPI to allow users and external systems to access.

OpenSooq.com → Extract → Raw CSV →
Transform → Cleaned CSV → Load → Postgre
→ FastAPI

Data Pipeline



No.

Date

تؤمّن سبب اختيار المعمارية :-

تم اعتماد هذه المعمارية «Layered Architecture» وذلك لفضل مراحل استخراج البيانات معالجتها، تخزينها، وعرضها عبر API. هذا التصميم يحقق عزلاً واختلاً للمسؤوليات «Separation of Concerns»، ويتيح التحكم فيما تدقق البيانات عبر مراحل ETL بشكل منظم، مع ضمان أن طبقة الـ API تعتمد فقط على بيانات منظمة ومنطقة خزانة البيانات. كما تدعم هذه المعمارية قابلية التوسع وإعادة الاستخدام، ويسهل تحويل النظام إلى خدمة تعمل بشكل مستقل ضمن بيئة ~~مستقلة~~ تشغيل مثل Ubuntu باستخدام Systemd.

Data Cleaning Steps:

- 1- Rows with missing Car names are removed and also duplicate records
- 2- Non-numeric characters in Price column are removed and converted to numeric
- 3- missing values in Price column are filled by median
- 4- Text columns such as name, description, status, location and country are normalized by trimming spaces and replacing missing values with null.
- 5- The Make and Mileage columns are converted into numeric
- 6- Convert posted_at to datetime.